

Avaliação de Políticas Públicas usando o R

Modelo de resultados potenciais

Vítor Wilher

Cientista de Dados | Mestre em Economia



Plano de Voo

Pacotes

Modelo de resultados potenciais

Comparando o antes e depois dos tratados

Comparando tratados e não tratados

Conclusão

Pacotes

Os pacotes que usaremos nessa seção estão listados abaixo. Sempre que possível, colocaremos os pacotes utilizados logo no início de cada seção.¹

```
library(tidyverse)
library(truncnorm)
library(knitr)

set.seed(2021)
```

¹É possível que algum dos pacotes listados tenha sido retirado sem prévio aviso do CRAN. Nesses casos, por favor, entre em contato com o nosso suporte.

Modelo de resultados potenciais

O modelo de resultados potenciais, ou **modelo causal de Rubin** [Rubin, 2004], é uma abordagem que visa estimar o efeito causal do tratamento com base nos resultados que potencialmente o mesmo indivíduo teria sem o tratamento. Como explicado na seção anterior, o problema com isso é que é impossível saber o que aconteceria com o indivíduo nesta “realidade alternativa” de não tratamento.

Efeito causal

Se a variável de interesse para o indivíduo i quando não há tratamento é $Y_i(0)$ e quando há tratamento é $Y_i(1)$

O efeito causal médio, derivado do modelo de resultados potenciais, é igual a:

$$E[Y_i(1) - Y_i(0)] \tag{1}$$

Hipótese da ignorabilidade condicional

Como não podemos ter acesso aos dois resultados ao mesmo tempo, não podemos estimar o impacto desta forma. Portanto é necessário incorrer na chamada hipótese da **"ignorabilidade condicional"**. Ou seja, de que a diferença entre o comportamento da variável de interesse para o grupo tratado e o grupo de controle seja apenas dependente do tratamento e de um conjunto de covariáveis observáveis:

$$\{Y_i(0), Y_i(1)\} \perp T \mid X \quad (2)$$

Hipótese da ignorabilidade condicional

Assim, a **robustez** do método utilizado para estimar um impacto de uma política passa por quão crível é essa hipótese no caso específico. Cabe mencionar, que essa hipótese não é testável. Um fator muito importante para isso é controlar bem a influência das covariáveis, evitando variáveis não observáveis. Por isso, é de grande importância a definição do grupo de controle utilizado.

Hipótese de Valor Estável da Unidade de Tratamento (SUTVA)

Outro ponto importante é a hipótese de Valor Estável da Unidade de Tratamento (**SUTVA**). Ou seja, os resultados potenciais de um indivíduo não podem ser afetados pelo desígnio de tratamento a outros indivíduos. Ou seja, não podem haver **spillovers** no estudo. Pode ser complicado evitar a violação desta hipótese em alguns casos.

Hipótese de Valor Estável da Unidade de Tratamento (SUTVA)

Por exemplo, digamos que uma empresa deseja analisar o impacto de uma política de treinamento de um setor. Pra isso, ela aleatoriza os funcionários escolhidos e realiza o treinamento. Mesmo que os grupos de tratamento e controle sejam balanceados, possivelmente o efeito estimado da política será menor que o efeito real, pois pode ocorrer um efeito de spillover de conhecimento entre os funcionários dos dois grupos.

Comparando o antes e depois dos tratados

O meio mais simples - e possivelmente o mais errado - de se avaliar uma política é comparar a situação dos indivíduos tratados antes e depois da política, sem nenhuma comparação com algum outro grupo que não sofreu a intervenção. Quando se faz isso, a hipótese implícita em que o avaliador incorre é a de que a situação dos grupos tratados permaneceria a mesma sem a política. Ou seja, que a variável de interesse é estática. Essa hipótese é *infactível* para quase qualquer avaliação de impacto.

Comparando o antes e depois dos tratados - Exemplo

Assim, utilizando o exemplo feito na primeira seção, que trata de uma política hipotética de transferência de renda, podemos estimar o efeito encontrado por esse tipo de abordagem. Imagine que por algum motivo não tenhamos acesso aos dados do grupo de controle. Neste caso, estimaremos o impacto do tratamento por meio da diferença entre a média da renda do grupo de tratamento no momento posterior com a média do mesmo grupo no momento anterior.

Comparando o antes e depois dos tratados - Exemplo

```
id <- seq(1:5000) #id de cada indivíduo

# distribuição normal truncada entre 0 e 1000
renda_antes <- rtruncnorm(n=5000, a=0, b=1000,
                          mean=500, sd=200)

tratamento <- as.factor(rbinom(n=5000, size=1, prob=0.5))
df <- data.frame(id, renda_antes, tratamento)
df$renda_depois <- renda_antes*1.1 +
  as.numeric(tratamento)*250 +
  rnorm(5000, mean = 50, sd = 50)
```

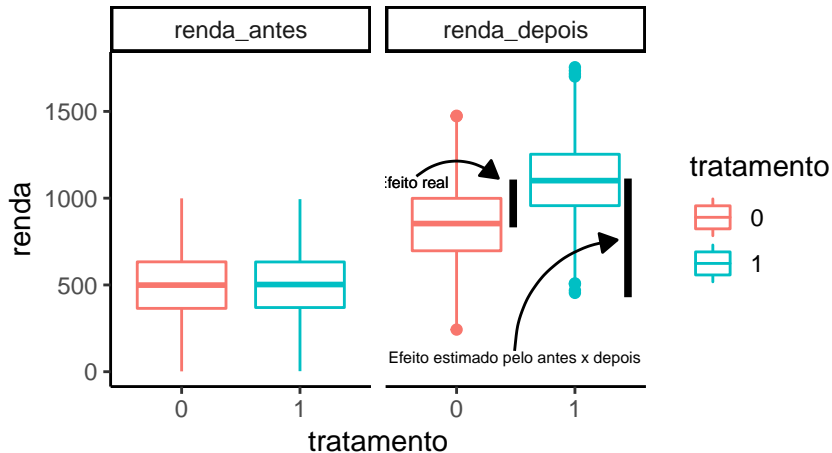
Comparando o antes e depois dos tratados - Exemplo

```
plot1 <- df %>%
  pivot_longer(!c(id, tratamento),
               names_to = "tempo",
               values_to = "renda") %>%

  ggplot() +
  geom_boxplot(aes(x = tratamento, y = renda, color = tratamento)) +
  facet_wrap(vars(tempo)) +
  theme_classic() +
  #a partir daqui o código só inclui as anotações
  geom_curve(data = data.frame(x = c(1.49, 0.66 ), y = c(120.16, 1126.31),
                                xend = c(2.357, 1.353), yend = c(759.364, 1114.47),
                                tempo = "renda_depois"),
             mapping = aes(x = x, y = y, xend = xend, yend = yend), curvature = -0.405,
             arrow = arrow(30L, unit(0.1, "inches"),
                           "last", "closed"), inherit.aes = FALSE) +
  geom_rect(data = data.frame(xmin = c(2.44, 1.47 ),
                               xmax = c(2.456, 1.4866), ymin = c(445.68, 848.14),
                               ymax = c(1096.72, 1090.801), tempo = "renda_depois"),
            mapping = aes(xmin = xmin, xmax = xmax, ymin = ymin, ymax = ymax),
            size = 1L, colour = "black", fill = "grey55", alpha = 0L, inherit.aes = FALSE) +
  geom_text(data = data.frame(x = c(1.491, 0.631, 0.631),
                               y = c(84.65, 1090.8019, 1090.801),
                               label = c("Efeito estimado pelo antes x depois", "Efeito real", "Efeito real"),
                               tempo = "renda_depois"), size=2,
            mapping = aes(x = x, y = y, label = label), inherit.aes = FALSE)
```

Comparando o antes e depois dos tratados - Exemplo

plot1



Comparando o antes e depois dos tratados - Exemplo

Veja que o efeito estimado por essa abordagem é bem maior que o efeito real.

```
tratados <- df %>%  
  filter(tratamento == 1)  
  
mean(tratados$renda_depois) - mean(tratados$renda_antes)
```

```
[1] 601.7619
```

Se pudessemos de alguma forma garantir que houvesse estabilidade da variável de interesse e nenhuma influência de nenhum outro fator, o efeito estimado por este método seria igual ao efeito real. Entretanto, na prática, esse tipo de abordagem nunca pode ser utilizada.

Comparando tratados e não tratados

Muitas vezes, é possível que seja aventada a hipótese de comparar o grupo que sofreu a intervenção com o restante da população que não foi alvo da política. Isso pode acontecer porque não houve aleatorização e a política já foi implementada. Definimos o restante da população podem ser os outros indivíduos do local, ou de diferentes locais. Por exemplo, pode-se estimar o efeito de uma política em uma região, comparando o comportamento da variável de interesse nos municípios desta região com os de outra região, que não foi afetada.

Comparando tratados e não tratados

Mesmo que nós tenhamos um grupo de controle, ele não necessariamente é adequado para ser comparado com os indivíduos tratados. É necessário que o grupo de controle tenha características semelhantes ao de tratamento. Assim, políticas que visam a intervenção em grupos bastante específicos vão apresentar grupos de tratamento bastante diferentes do restante da sociedade.

Comparando tratados e não tratados - Exemplo

Podemos utilizar o mesmo exemplo de anteriormente para demonstrar isso. Para isso, é preciso modificar um pouco a estrutura do que foi feito. Ao invés de realizar um estudo e aleatorizar a escolha de quem será tratado ou não, o gestor da política decidiu implementar a política com base nos mesmos critérios, sem a definição de um grupo de controle. Obviamente, a média da renda do restante da população é maior do que a do grupo alvo da política. Entretanto, assumimos a mesma relação entre a renda do período t e do período $t + 1$ e o mesmo efeito real do tratamento.

Comparando tratados e não tratados - Exemplo

```
tratados <- data.frame(renda_antes = rtruncnorm(n=5000, a=0,
                                                b=1000, mean=500,
                                                sd=200),
                      id = seq(1:5000),
                      tratamento = as.factor(1))

restante <- data.frame(renda_antes = rtruncnorm(n=5000, a=1000,
                                                b=10000, mean=2000,
                                                sd=400),
                      id = seq(5001:10000),
                      tratamento = as.factor(0))

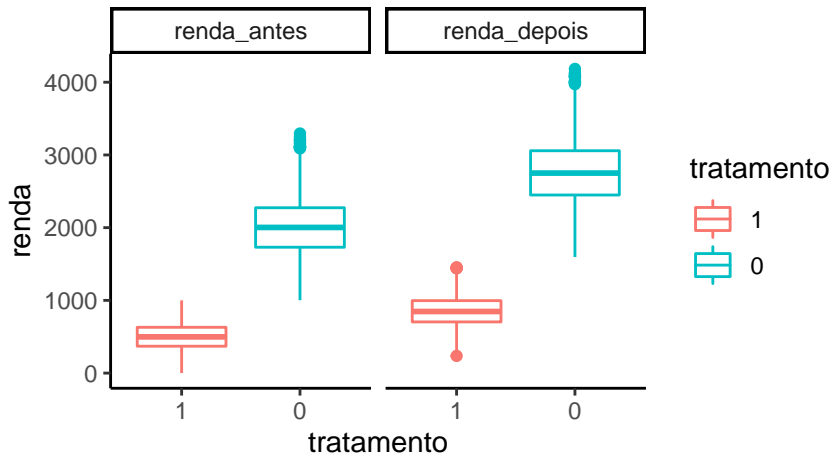
df = rbind(tratados, restante)
```

Comparando tratados e não tratados - Exemplo

```
df$renda_depois <- df$renda_antes*1.1 +  
  as.numeric(df$tratamento)*250 +  
  rnorm(10000, mean = 50, sd = 50)  
  
plot2 <- df %>%  
  pivot_longer(!c(id, tratamento),  
               names_to = "tempo",  
               values_to = "renda") %>%  
  ggplot() +  
  geom_boxplot(aes(x = tratamento, y = renda, color = tratamento)) +  
  facet_wrap(vars(tempo)) +  
  theme_classic()
```

Comparando tratados e não tratados - Exemplo

plot2



Comparando tratados e não tratados - Exemplo

Perceba que o efeito desaparece, devido às características diferentes entre os dois grupos. Na verdade, quando estimamos um modelo de **diferenças-em-diferenças**, que detalharemos no decorrer do curso, o efeito estimado do tratamento torna-se negativo.

```
diff = df %>%  
  mutate(diff = renda_depois - renda_antes) %>%  
  group_by(tratamento) %>%  
  summarise_at(vars(-id), funs(mean(., na.rm=TRUE)))  
  
kable(diff)
```

tratamento	renda_antes	renda_depois	diff
1	498.9617	848.4187	349.4570
0	2008.3259	2758.0702	749.7443

```
diff$diff[1] - diff$diff[2]
```

```
[1] -400.2873
```

Conclusão

Assim, a escolha do grupo de controle se mostra essencial para o impacto estimado de uma política ser semelhante ao impacto real. Então, quando o grupo alvo de uma política diferir do restante da população em características relevantes, é preciso adequar o grupo de controle. A primeira possibilidade, que já vimos resumidamente é a de aleatorização. Esse é o modelo que pode ser considerado ideal, mas também apresenta dificuldades de execução e custos elevados. A segunda é buscar na população indivíduos com propriedades semelhantes aos tratados para compor o grupo de controle. Essas abordagens serão melhor detalhadas nas seções 4 e 6, respectivamente.

Referências I

Donald B Rubin. Direct and indirect causal effects via potential outcomes. *Scandinavian Journal of Statistics*, 31(2):161–170, 2004.